




Bienvenido a la Isla Desconocida

El **aprendizaje no supervisado** parte de datos sin clasificar: no hay variable objetivo ni etiquetas previas. El objetivo es descubrir patrones ocultos y agrupar los datos por su propia estructura. Imagina que estás en una región nueva **sin Pokédex**: debes agrupar criaturas basándote solo en lo que ves.

Mariajose A

BOA WCE
Traeiner

BOA WCE



¿Qué es el Clustering?

Técnica para encontrar **subgrupos o clusters** en un conjunto de datos, organizándolos según sus similitudes internas sin conocimiento previo.

Un único grupo

Cada elemento pertenece a **exactamente un** cluster.

Sin excepciones

Todo elemento debe estar **asignado a algún** grupo.

Homogéneos y separados

Los grupos son **similares internamente** y bien diferenciados entre sí.



ALGORITMO DE LLOYD

K-Means: El Método de los Líderes

Divide N registros en K grupos minimizando la distancia de cada punto al centro de su cluster.

Centroide

El punto central o «líder» de cada grupo.


K

Número de grupos que **decidimos de antemano**.

Celdas de Voronoi


El algoritmo divide el espacio en polígonos que delimitan la influencia de cada centroide.

El Flujo del Algoritmo



El proceso se repite iterativamente hasta que los grupos dejan de cambiar o se alcanza el límite de iteraciones. En cada ciclo, los centroides se «mueven» hacia la posición óptima de su cluster.

Similitud y Distancia




Distancia Euclídea

Medida más común para comparar registros en espacios cuantitativos. Cuanto **menor** es la distancia, más similares son los elementos.

Estandarización: paso obligatorio

Si los atributos tienen escalas distintas (ej. Vida 0–1000 vs. Velocidad 0–10), la distancia queda dominada por las unidades mayores. La solución: **restar la media y dividir por la desviación típica** para que cada variable contribuya por igual.

¿Cuántos Equipos Necesito? El Método del Codo



La Inercia (SSE)

Suma de las distancias al cuadrado de cada punto a su centroide. A mayor K , menor inercia.

El «codo» óptimo

El punto donde la caída deja de ser brusca indica el número ideal de grupos: añadir más clusters ya no aporta información relevante.



En el ejemplo, el codo aparece en **K=3**: a partir de ahí, la mejora es marginal.

¿Están Felices los Pokémon? El Coeficiente de Silueta

$si \approx 1$

Elemento **bien ubicado**: muy cercano a su grupo y lejos del vecino más próximo.

$si \approx 0$

Frontera difusa: el elemento está a igual distancia de dos clusters superpuestos.

$si < 0$

Mal asignado: el elemento estaría mejor en el cluster vecino.





Ventajas y Limitaciones

Puntos Fuertes

- Muy **eficiente** y converge rápidamente en datos grandes
- Simple de implementar e interpretar
- Escalable a millones de registros

Debilidades de Tipo

- No es robusto ante **outliers**: un punto atípico puede arrastrar el centroide
- No detecta grupos de formas **no convexas**
- Depende de la **inicialización aleatoria** de los centroides

VALIDACIÓN EXTERNA

El Índice de Rand Ajustado (ARI)

Mide la similitud entre nuestra partición y una clasificación de referencia (expertos o etiquetas reales).



$ARI = 1.0$

Nuestras cajas son **idénticas** a las del experto.



$ARI = 0.0$

Agrupamos **al azar**: sin concordancia con la referencia.



El Poder del Agrupamiento

K-Means descubre estructuras ocultas sin etiquetas. La clave: **estandarizar** los datos, elegir K con el **método del codo** y validar con la **silueta**.

01

Estandarizar

Normaliza las escalas antes de calcular distancias.

02

Elegir K

Usa el método del codo y el coeficiente de silueta.

03

Validar

Aplica ARI si dispones de etiquetas de referencia.

Links de Interés

<https://www.youtube.com/watch?v=oT3arRRB2Cw>

<https://www.naftaliharris.com/blog/visualizing-k-means-clustering/>

https://scikit-learn.org/stable/modules/generated/sklearn.datasets.make_blobs.html